

Tarea: Modelamiento de tasas mediante regresión Poisson

INSTRUCCIONES: La tarea debe ser desarrollada en grupos de dos a tres personas utilizando R. Todas las respuestas deben ser justificadas e interpretadas en el contexto del problema. No es necesario incluir toda la salida de R; reporte solamente los resultados relevantes.

La nota final de la tarea se compone de:

- **Informe escrito (50 %):** debe contener el desarrollo de los problemas, los resultados obtenidos y su correspondiente interpretación.
- **Presentación oral (50 %):** cada grupo deberá realizar una presentación de **5 minutos**, en la que se presentarán los datos utilizados, la pregunta de investigación y la motivación para utilizar regresión de Poisson, justificando la inclusión o no de un término *offset*.

Posteriormente se realizarán aproximadamente **10 minutos de preguntas**, que podrán estar dirigidas a cualquiera de los integrantes. Las preguntas podrán referirse tanto a los contenidos del curso como a las decisiones metodológicas y afirmaciones realizadas en el informe.

Tanto el informe como la presentación deben enfocarse en la interpretación de los resultados y en las principales conclusiones, evitando limitarse a mostrar código o salidas de R.

FECHA DE ENTREGA: 12 de octubre 17:00.

SELECCIÓN DE LA BASE DE DATOS

Cada grupo deberá seleccionar una base de datos real. Se recomienda utilizar datos públicos, por ejemplo, datos REM del Ministerio de Salud, aunque podrán utilizarse otras fuentes. **La base de datos y el problema seleccionado deberán cumplir con los siguientes requisitos:**

- La variable respuesta Y debe ser un **conteo**: número de casos, eventos, atenciones, personas, hospitalizaciones, etc.
- Deben utilizarse al menos **tres covariables explicativas** en el análisis.
- La unidad de observación debe estar claramente definida. Por ejemplo: región–sexo–grupo etario, establecimiento–mes, comuna–año, etc.
- Se recomienda que la base contenga al menos **80 observaciones útiles** luego del proceso de limpieza y preparación de los datos.
- Cuando exista una variable de **exposición** $E_i > 0$ con una interpretación clara, esta deberá incorporarse mediante un *offset*. En este caso, se modelará una tasa utilizando

$$\log(\mu_i) = \log(E_i) + \beta_0 + \beta_1 X_{i1} + \cdots + \beta_p X_{ip},$$

donde $\log(E_i)$ corresponde al *offset*.

El *offset* debe tener una interpretación sustantiva como medida de exposición, tiempo en riesgo o tamaño del grupo. No basta con seleccionar una variable positiva y utilizar su logaritmo.

También podrán considerarse problemas en los que no corresponda utilizar un *offset*. En ese caso, el grupo deberá justificar claramente por qué el objetivo del análisis es modelar directamente el conteo esperado y por qué no existe una medida de exposición que deba ser incorporada al modelo.

2. Análisis requerido

2.1. Pregunta y descripción de los datos

El informe debe comenzar con una **pregunta estadística clara**, que guíe las decisiones tomadas durante el análisis. Por ejemplo:

¿Cómo cambia la tasa de un determinado evento según sexo, grupo etario y región, ajustando por el número de personas expuestas?

Luego deberán describir brevemente la base de datos, indicando la unidad de observación, la variable respuesta, las covariables consideradas, la fuente de los datos y la variable de exposición utilizada.

Se espera que, cuando exista una medida natural de exposición E , esta se incorpore mediante un *offset* $\log(E)$. Se deberá explicar qué representa dicha exposición y por qué corresponde modelar una tasa.

Si se decide trabajar **sin *offset***, esta elección deberá estar claramente justificada de acuerdo con la naturaleza del problema y la variable respuesta.

2.2. Análisis descriptivo

Antes de ajustar los modelos, cada grupo deberá realizar una exploración descriptiva de los datos. El informe debe incluir, como mínimo:

- **Una tabla descriptiva** de las variables principales utilizadas en el análisis.
- **Al menos dos gráficos descriptivos** que permitan explorar el comportamiento de la variable respuesta y su relación con covariables relevantes.
- Si se utiliza una variable de exposición E , **al menos uno de los gráficos deberá mostrar la tasa observada Y/E** según alguna covariable relevante.
- **Una breve descripción e interpretación** de los principales patrones observados en las tablas y gráficos.

Los gráficos y tablas deben ser pertinentes para la pregunta de investigación y estar correctamente identificados. No basta con incluirlos: los principales resultados descriptivos deben ser comentados en el texto.

2.3. Modelos de Poisson

Cada grupo deberá ajustar y comparar al menos **tres modelos de regresión de Poisson**. Si se utiliza una variable de exposición E , todos los modelos deberán incorporar el *offset* $\log(E)$.

El análisis deberá incluir, como mínimo:

- **Tres modelos distintos**, que formen parte de una estrategia de modelamiento coherente con la pregunta de investigación.
- Los **tres modelos propuestos, en conjunto**, deberán cumplir además las siguientes condiciones:
 - al menos **dos deberán ser multivariantes**, incorporando conjuntamente las principales covariables del estudio;
 - al menos **uno deberá incluir una interacción** entre dos covariables. La elección de esta interacción deberá tener una interpretación razonable en el contexto del problema.
- Para cada modelo, se deberá indicar:
 - la fórmula utilizada;

- las covariables incluidas;
 - las categorías de referencia;
 - una breve justificación de por qué se propone ese modelo.
- Se deberán interpretar los parámetros más relevantes de los modelos, utilizando razones de tasas (*IRR*) cuando corresponda.

Importante: no basta con ajustar tres modelos diferentes únicamente para cumplir con el número mínimo solicitado. Por ejemplo, ajustar por separado

$$Y \sim X_1, \quad Y \sim X_2, \quad Y \sim X_3$$

no constituye, por sí solo, una estrategia adecuada de comparación de modelos.

Durante la **defensa oral** se podrá solicitar al grupo que justifique las decisiones metodológicas tomadas, incluyendo la selección de covariables, la construcción de los modelos y la elección de interacciones. Una decisión que no pueda ser justificada de manera coherente con la pregunta de investigación y los datos podrá implicar una disminución del puntaje correspondiente.

2.4. Comparación de modelos

Los modelos ajustados deberán compararse utilizando los mismos criterios. El informe debe incluir:

- **Una tabla comparativa** que contenga, para cada modelo:
 - AIC;
 - deviance residual / grados de libertad;
 - error cuadrático medio (ECM).
- El **ECM** deberá calcularse en la escala de la respuesta, comparando los conteos observados Y_i con los conteos esperados $\hat{\mu}_i$, de la misma forma para todos los modelos:

$$\text{ECM} = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{\mu}_i)^2.$$

- Una **comparación de los modelos** a partir de los resultados anteriores, indicando si los distintos criterios conducen o no a conclusiones similares.
- La **selección de un modelo final**, acompañada de una justificación que considere su ajuste, complejidad e interpretación.

Por ejemplo:

Modelo	AIC	Deviance/df	ECM
Modelo 1			
Modelo 2			
Modelo 3			

No basta con identificar el modelo con menor AIC o ECM: la elección final deberá ser discutida y justificada.

2.5. Interpretación de resultados

A partir de los modelos ajustados, el informe deberá incluir:

- La interpretación de **al menos dos IRR relevantes**, incluyendo sus intervalos de confianza al 95 %.
- La interpretación de **al menos una comparación que involucre la interacción** incluida en el análisis.
- El cálculo e interpretación de la **predicción para al menos un grupo o perfil específico**. Si se utiliza un *offset*, se deberá calcular e interpretar la tasa esperada $\hat{\mu}_i/E_i$; si no se utiliza *offset*, se interpretará el conteo esperado $\hat{\mu}_i$.
- Si se utiliza un *offset*, una **explicación de su interpretación** en el contexto del problema.

Todas las interpretaciones deben expresarse en el contexto del problema estudiado. No basta con reportar coeficientes o copiar directamente la salida de R.

2.6. Conclusiones

El informe deberá finalizar con una síntesis breve que incluya:

- una **respuesta a la pregunta de investigación** planteada al comienzo del informe;
- los **principales hallazgos** del análisis;
- el **modelo seleccionado** y una breve justificación de su elección;
- al menos una **limitación relevante** del análisis.

Las conclusiones deben estar respaldadas por los resultados obtenidos y no incorporar afirmaciones que no puedan sustentarse a partir del análisis realizado.

3. Presentación y defensa oral

Cada grupo realizará una **presentación de 5 minutos**, seguida de aproximadamente **10 minutos de preguntas**.

3.1. Presentación

La presentación deberá centrarse en comunicar de manera clara el problema estudiado y los principales patrones observados en los datos. Deberá incluir:

- **Pregunta de investigación:** explicar brevemente qué problema se estudia y cuál es la pregunta que guía el análisis.
- **Descripción de los datos:** indicar la fuente, unidad de observación, variable respuesta, covariables y variable de exposición, si corresponde.
- **Análisis descriptivo:** presentar uno o dos gráficos o tablas que permitan comprender los principales patrones de los datos.
- **Resultado principal:** indicar brevemente qué modelo fue seleccionado y cuál es la principal conclusión obtenida a partir del análisis.

La presentación debe estar diseñada para una duración máxima de **5 minutos**. No se espera presentar en detalle la salida de R, todos los coeficientes estimados ni el desarrollo completo de los tres modelos.

3.2. Diapositivas de respaldo

Además de las diapositivas utilizadas durante la presentación, cada grupo deberá incluir al final del archivo algunas **diapositivas de respaldo**, que no necesariamente serán presentadas durante los 5 minutos.

Estas deberán contener, como mínimo:

- la especificación de los **tres modelos de Poisson** considerados;
- la **tabla de comparación de modelos** con AIC, deviance/df y ECM;
- la salida o una tabla resumen con los **coeficientes estimados del modelo seleccionado**, incluyendo errores estándar o intervalos de confianza;
- las **IRR e intervalos de confianza** más relevantes;
- la información necesaria para interpretar la **interacción** incluida en el análisis.

3.3. Defensa oral

Luego de la presentación se realizará una defensa oral de aproximadamente **10 minutos**. Durante esta instancia se podrán formular preguntas sobre cualquier parte del análisis, incluyendo:

- la elección de la variable respuesta, covariables y *offset*;
- la construcción y justificación de los modelos;
- la interpretación de coeficientes, IRR e interacciones;
- la comparación y selección de modelos;
- el cálculo e interpretación de predicciones;
- las decisiones metodológicas tomadas durante el análisis.

Los estudiantes deberán ser capaces de **explicar y justificar las decisiones realizadas en su propio análisis**. Las respuestas durante la defensa oral podrán afectar el puntaje asociado a los distintos componentes del trabajo si muestran que una decisión metodológica no está correctamente comprendida o justificada.