

Tarea: Regresión lineal múltiple y regularización

INSTRUCCIONES: La tarea debe ser desarrollada en grupos de dos personas utilizando R. Todas las respuestas deben ser justificadas e interpretadas en el contexto del problema. No es necesario incluir toda la salida de R; reporte solamente los resultados relevantes.

La nota final de la tarea se compone de:

- **Informe escrito (50 %):** debe contener el desarrollo de los problemas, los resultados obtenidos y su correspondiente interpretación.
- **Presentación oral (50 %):** cada grupo deberá realizar una presentación de **10 minutos**, en la que deberá sintetizar y discutir los hallazgos más importantes del análisis. Ambos integrantes deberán participar.

Posteriormente se realizarán aproximadamente **5 minutos de preguntas**, que podrán estar dirigidas a cualquiera de los integrantes. La evaluación considerará principalmente la comprensión del análisis, la interpretación de los resultados y la justificación de las decisiones metodológicas.

Tanto el informe como la presentación deben enfocarse en la interpretación de los resultados y en las principales conclusiones, evitando limitarse a mostrar código o salidas de R.

FECHA DE ENTREGA: 7 de septiembre 23:59:59.

En esta tarea utilizaremos la base de datos **Credit**, disponible en el paquete ISLR2:

```
library(ISLR2)
data(Credit)
```

La variable respuesta será **Balance**, correspondiente al saldo promedio de la tarjeta de crédito.

Problema 1: Regresión lineal múltiple

Considere el modelo

$$\text{Balance}_i = \beta_0 + \beta_1 \text{Income}_i + \beta_2 \text{Limit}_i + \beta_3 \text{Cards}_i + \beta_4 \text{Age}_i + \varepsilon_i.$$

1. Ajuste el modelo utilizando mínimos cuadrados y escriba la ecuación estimada.
2. Interprete, en el contexto del problema, los coeficientes asociados a **Income** y **Limit**.
3. Utilizando un nivel de significancia de $\alpha = 0,05$, indique cuáles variables presentan evidencia de asociación con **Balance**. Plantee las hipótesis correspondientes.
4. Reporte e interprete R^2 y R^2_{aj} . Además, realice el test F global y entregue una conclusión.

Problema 2: Selección de modelos

1. Ajuste un modelo que utilice todas las variables disponibles:

$$\text{Balance} \sim .$$

Compare este modelo con el del Problema 1 utilizando R^2_{aj} y AIC. ¿Cuál preferiría? Justifique.

2. A partir del modelo completo, realice selección de variables mediante AIC utilizando un procedimiento *backward*. Reporte el modelo finalmente seleccionado y comente brevemente las principales diferencias respecto del modelo completo.

Problema 3: Multicolinealidad

1. Calcule la matriz de correlaciones entre las variables explicativas numéricas. ¿Qué pares de predictores presentan las correlaciones más altas?
2. Considere el modelo que incluye como predictores `Income`, `Limit`, `Rating`, `Cards`, `Age` y `Education`. Calcule el factor de inflación de varianza (VIF) para cada predictor.
¿Qué variables presentan los valores más altos de VIF? ¿Existe evidencia de problemas de multicolinealidad? Justifique.
3. Explique brevemente por qué la presencia de predictores altamente correlacionados puede dificultar la interpretación de los coeficientes de un modelo de regresión.

Problema 4: Predicción y regularización

Una estrategia ampliamente utilizada para estimar el desempeño predictivo de un modelo es la validación cruzada K -fold.

1. Investigue brevemente en qué consiste la validación cruzada K -fold y explique con sus propias palabras cómo permite estimar el error predictivo.
Para los análisis siguientes utilice una única partición de los datos en $K = 5$ folds, fijando previamente la semilla mediante `set.seed(123)`. La misma partición deberá utilizarse para comparar los tres procedimientos.
2. Implemente validación cruzada con $K = 5$ para el modelo lineal completo. En cada fold calcule

$$\text{RMSE}_k = \sqrt{\frac{1}{n_k} \sum_{i \in \mathcal{I}_k} (Y_i - \hat{Y}_i)^2}.$$

Reporte el RMSE promedio de los cinco folds.

3. Repita el procedimiento utilizando selección de variables mediante AIC. La selección debe realizarse utilizando únicamente las observaciones de entrenamiento de cada fold.
Reporte el RMSE promedio obtenido.
4. Considere ahora regresión Ridge. Utilice la misma partición en $K = 5$ folds. En cada fold:
 - a) seleccione $\lambda_{\min}$ mediante `cv.glmnet()` con $\alpha = 0$, utilizando únicamente los datos de entrenamiento;
 - b) utilice el modelo obtenido para predecir las observaciones del fold de validación;
 - c) calcule el RMSE correspondiente.

Reporte el RMSE promedio obtenido y explique brevemente qué representa $\lambda_{\min}$.

5. Resuma sus resultados en una tabla:

Procedimiento	RMSE promedio
Modelo lineal completo	
Selección mediante AIC	
Regresión Ridge	

¿Qué procedimiento utilizaría si el objetivo principal fuera predecir el `Balance` de un nuevo individuo? Justifique su respuesta.

Conclusión

En no más de **100 palabras**, sintetice los principales hallazgos del análisis. En particular, comente qué variables parecen relevantes, si existe evidencia de multicolinealidad y qué procedimiento presentó el mejor desempeño predictivo.